

Q₁ :

分數: $\text{Score}(x) = \nabla_x \log p(x)$

- 給定機率密度函數 $p(x)$, 則某個 data point x 的分數為: 該點對數機率密度函數的梯度
- 指向 x 附近機率密度函數增長的方向

分數匹配: 訓練 $S(x; \theta)$ 使其盡可能準確估計出真實數據分佈在 x 的分數

方法一: ESM, $L_{\text{ESM}}(\theta) = E_{x \sim p(x)} \| S(x, \theta) - \nabla_x \log p(x) \|^2$

方法二: ISM, $L_{\text{ISM}}(\theta) = E_{x \sim p(x)} [\| S(x, \theta) \|^2 + 2 \nabla_x \cdot S(x, \theta)]$

- 避免未知值, 但 $\nabla_x \cdot S(x, \theta) = \text{tr}(\nabla S)$ 計算成本高

方法三: DSM, $L_{\text{DSM}}(\theta) = E_{x_0 \sim p_0(x_0)} E_{x_1 | x_0 \sim p(x_1 | x_0)} [\| S_\sigma(x; \theta) - \nabla_x \log p(x | x_0) \|^2]$

- 我不在試著找乾淨資料點 x_0 的 Score, 改成訓練一個噪音干擾後 x 的 Score. 目標是在學習一個向量場使 x 能指回 x_0 .

- 當我們 Gaussian noise ($x = x_0 + \varepsilon$)

此時 $\nabla_x \log p(x | x_0) = -\frac{1}{\sigma^2} (x - x_0)$

則 $L_{\text{DSM}} = E_{x_0 \sim p_0(x_0)} E_{x_1 | x_0 \sim p(x_1 | x_0)} \| S_\sigma(x; \theta) + \frac{x - x_0}{\sigma^2} \|^2$

- 使其計算成本得以簡化, 並從複雜無監督密度估計問題, 變成有目標的監督式回歸問題

使用方式

(1...t...T)

前向傳播: 從乾淨的圖像 x_0 開始, 在經過上千百步後, 途中逐步添加 Gaussian noise, 最後到了 T 步後, 會生成一張沒有結構的完全隨機噪音圖 x_T

訓練: 訓練一個 Neural Network, 使其能預測逆向的方向, DSM 即說明與其去找複雜的 Score, 不如直接訓練預測在某一步被添加 noise

反向傳播：改成相同大小的完全隨機噪音圖 x_T 開始。

從 T 一步步往回走

- 1. 將 x_t 的圖及 t 步輸入
- 2. model 預測 x_t 的 noise
- 3. $x_t - \text{預測 noise} \rightarrow x_{t-1}$

迭代去噪至 $t=0$ 時， x_0 即為全新、清晰的圖像

Q：目前 Score Matching 的討論都是基於連續變數(圖片)
但我能擴張到離散資料嗎？(文字)，此時梯度 ∇_x ？

Q：如果我的 data distribution 是多個 multimodal 是不是會生成
Failure Modes？換句話說，產生 Failure Modes 的可能有哪些？