

## Q1 : Consider a forward

$$dx_t = f(x_t, t)dt + g(x_t, t)dW_t$$

show that the corresponding PF - ODE is written as

$$dx_t = \left[ f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x} g^2(x_t, t) - \frac{g^2(x_t, t)}{2} \frac{\partial}{\partial x} \log p(x_t, t) \right] dt$$

Ans:

Forward SDE -> 給定一個前向隨機微分方程 (SDE) :

$$dx_t = f(x_t, t)dt + g(x_t, t)dW_t$$

**Fokker-Planck Equation** : 此 SDE 對應的機率密度  $p(x, t)$  遵循 Fokker-Planck 方程式

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x} [f(x, t)p(x, t)] + \frac{1}{2} \frac{\partial^2}{\partial x^2} [g^2(x, t)p(x, t)]$$

我們可以將上式重新整理，使其符合「連續性方程」的形式

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x} \left[ f(x, t)p(x, t) - \frac{1}{2} \frac{\partial}{\partial x} (g^2(x, t)p(x, t)) \right]$$

Probability Flow (PF) ODE :

我們尋求一個確定性的常微分方程 (ODE)，其形式為  $dx_t = \tilde{f}(x_t, t)dt$ 。此 ODE 對應的機率密度  $p(x, t)$  必須遵循連續性方程：

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x} [\tilde{f}(x, t)p(x, t)]$$

求解  $\tilde{f}$

為了讓 SDE 和 ODE 產生相同的機率密度  $p(x, t)$ ，它們各自的  $\frac{\partial p}{\partial t}$  必須相等。也就是

$$-\frac{\partial}{\partial x} [\tilde{f}(x, t)p(x, t)] = -\frac{\partial}{\partial x} \left[ f(x, t)p(x, t) - \frac{1}{2} \frac{\partial}{\partial x} (g^2(x, t)p(x, t)) \right]$$

令中括號內的變量相等：

$$\tilde{f}(x, t)p(x, t) = f(x, t)p(x, t) - \frac{1}{2} \frac{\partial}{\partial x} (g^2(x, t)p(x, t))$$

對兩邊同除以  $p(x, t)$  :

$$\tilde{f}(x, t) = f(x, t) - \frac{1}{2p(x, t)} \frac{\partial}{\partial x} (g^2(x, t)p(x, t))$$

對  $\frac{\partial}{\partial x} (g^2 p)$  使用乘法法則 (Product Rule) :

$$\tilde{f}(x, t) = f(x, t) - \frac{1}{2p(x, t)} \left[ \left( \frac{\partial g^2}{\partial x} \right) p(x, t) + g^2(x, t) \left( \frac{\partial p}{\partial x} \right) \right]$$

化簡可得 :

$$\tilde{f}(x, t) = f(x, t) - \frac{1}{2} \frac{\partial g^2}{\partial x} - \frac{g^2(x, t)}{2} \left( \frac{1}{p(x, t)} \frac{\partial p}{\partial x} \right)$$

最後，我們引入 Score Function  $\nabla_x \log p = \frac{1}{p} \frac{\partial p}{\partial x}$

$$\tilde{f}(x, t) = f(x, t) - \frac{1}{2} \frac{\partial g^2(x, t)}{\partial x} - \frac{g^2(x, t)}{2} \frac{\partial}{\partial x} \log p(x, t)$$

因此，**PF - ODE** 為：

$$dx_t = \left[ f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x} g^2(x_t, t) - \frac{g^2(x_t, t)}{2} \frac{\partial}{\partial x} \log p(x_t, t) \right] dt$$

---

## Q2 : AI 的未來與機器學習的基石(使用gemini協助建構學習策略)

我認為 20 年後 AI 能做到的重要大事，是建立「個人化的心智計算模型」。這將徹底改變精神健康領域，從「被動治療」轉向「主動預防」，並成為精神科醫生最強大、也最不可或缺的輔助系統。

### 核心能力、應用與醫病協作

- 今日 **AI 的極限**：僅能進行模式匹配，如：找出「睡眠」與「憂鬱」的相關性，卻無法理解為什麼（如：個性、病史等主觀因素）。
- **20 年後的 AI**：能建立「心智因果模型」，深刻理解從「觸發點」到「核心信念」、再到「症狀」的個人化主觀運作機制，從「看症狀」進化到「懂機制」。
- **具體應用與協作**：
  1. **醫生制定戰略**：醫生診斷病患（如社交焦慮）並制定 CBT 治療策略。
  2. **AI 校準模型**：在醫生指導下，AI 建立模型，挖掘出「害怕主管點名」才是真正的焦慮觸發點。
  3. **AI 執行戰術**：AI 成為醫生的「延伸」，在會議前預測焦慮並主動介入，執行 CBT 戰術：「偵測到壓力，模型顯示與『擔心主管』一致。執行 60 秒認知練習。」
  4. **醫生迭代優化**：AI 於回診時提供「干預總結報告」，幫助醫生依客觀數據微調策略。

AI 的角色不是「AI 醫師」，而是「戰術執行官」與「數據科學家」。真正的主導權、同理心與治療決策，始終掌握在人類醫生手中。

## 核心機器學習方法

這必須是三種學習的組合：

### 1. 非監督式學習：

- **目的：**奠定基礎。AI 從海量個人數據（心率、語音等）中，自動找出獨特的「隱藏狀態」或「行為基線」（如『疲憊』、『焦慮前兆』）。

### 2. 監督式學習：

- **目的：**校準模型。AI 依賴使用者稀疏的主觀回饋（如「我很焦慮」）為「標籤」（Y），將客觀的「狀態」（X）映射到主觀感受。

### 3. 強化學習：

- **目的：**決定「行動」。最關鍵的步驟。AI 學習在何時、採取何種「干預措施」，以獲得「長期健康改善」的最佳獎勵。此獎勵函數的定義，由精神科醫生主導設計。

## 第一步的簡化模型

起始點：「預測並干預學習者的『心流』或『卡關』狀態」

- **概念連結：**「卡關」就像「焦慮」，是一種主觀狀態。AI 必須學習從「客觀行為」（如打字速度、錯誤率、眼動）去推斷這種主觀的「卡關」狀態。
- **可測試性：**讓 AI 預測受試者卡關了，並主動給予提示。然後觀察實驗組的「學習效率」是否顯著高於對照組。
- **工具：**透過時間序列模型（如 RNN/Transformer）來處理行為數據，並用隱馬可夫模型（HMM）來定義「心流」和「卡關」的狀態轉換。

---

## Q3:

Q3-1:

PF - ODE：

$$dx_t = \left[ f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x} g^2(x_t, t) - \frac{g^2(x_t, t)}{2} \frac{\partial}{\partial x} \log p(x_t, t) \right] dt$$

當  $g(x_t, t)$  不依賴  $x_t$ （即  $g(x_t, t) = g(t)$ ）時，PF-ODE 簡化為：

$$dx_t = \left[ f(x_t, t) - \frac{g^2(t)}{2} \frac{\partial}{\partial x} \log p(x_t, t) \right] dt$$

$\nabla_x \log p$  (Score function) 我們可以用 DSM 解決，但如果  $g$  依賴  $x_t$ ，多出來的  $\frac{\partial}{\partial x} g^2(x_t, t)$  項在實作上該如何學習？

Q3-2：

在反向過程中，越接近  $t = 0$  (真實照片)， $\nabla_x \log p_t(x_t)$  會越陡峭。 $\Delta t$  小可以很好的還原，但很耗時。 $\Delta t$  可以省時，但快還原時容易放大誤差造成怪點。

那我們有辦法做個**非線性**的  $\Delta t$  來達到省時跟精準的優勢嗎？